

Relatório de Avaliação de Vieses

Classificador de categorias de uso de IA do GuardIA (protótipo v0.1)

Versão	1.1	Data	02/10/2026
Responsável	Equipe GuardIA (Ellen Beatryz · Luana Cavalcanti · Márcia Rejane · Deivison Amorim · Denilson Lima)	Riscos	T05 Viés (principal) · T03 Desempenho · T06 Supervisão humana · E5 Rotulação e estigmatização
Requisitos	RF03 (painel por categoria) · RF04 (alertas revisáveis)	Evidências	evidencias/avaliacao_vieses.py · dataset_sintetico_v1.0.csv · resultados_v1.0.json

1. Objetivo e pergunta de avaliação

A análise de riscos aponta que linguagem informal, regionalismos e diferentes faixas etárias podem alterar o desempenho do classificador que alimenta o painel (RF03) e os alertas (RF04). Este relatório testa, com dados **sintéticos**, a pergunta: o classificador de categorias tem desempenho diferente conforme o registro de linguagem e a faixa etária da mensagem? O objetivo é demonstrar o **método** de avaliação e identificar riscos já visíveis no protótipo, e não certificar o sistema.

2. Método

Classificador avaliado. Como o classificador por LLM (artefato 01) ainda não está contratado, avaliou-se o protótipo v0.1 baseado em regras: léxico de cerca de 60 termos em 4 categorias (escola, entretenimento, socialização, apoio emocional), com normalização de acentos e caixa. Sem correspondência, a saída é “outros”; em empate, vale uma ordem fixa de categorias. O léxico foi escrito **antes** do teste, em português padrão, e **não foi ajustado depois** de ver os resultados. O mesmo protocolo vale para trocar o classificador por um LLM.

Métricas. Acurácia; precisão e revocação por categoria; taxa de falso alerta (mensagens de outras categorias classificadas como a categoria em questão); matriz de confusão. Cada métrica foi calculada no total, por registro de linguagem e por faixa etária.

Reprodução. python3 avaliacao_vieses.py regenera o dataset, os resultados e o gráfico. Não há aleatoriedade.

3. Conjunto de teste


72 mensagens curtas, escritas pela equipe, sem nomes, lugares ou dados pessoais: 4 categorias × 3 registros × 6 mensagens. As faixas etárias (6-9, 10-12, 13-15, 16-17) foram atribuídas em rodízio, sendo 18 mensagens por faixa.

Registro	Descrição	Exemplos sintéticos
neutro	Português padrão, frases completas	“Estou ansioso com a prova e não consigo dormir direito.”
informal	Gírias e escrita de chat	“mano tô na bad faz dias, nem sei explicar”
regional	Expressões nordestinas	“oxe, tô com uma agonia no peito que num passa”

4. Resultados

4.1 Por registro de linguagem

Registro	n	Acurácia	Revoc. escola	Revoc. entret.	Revoc. social.	Revoc. apoio emoc.	Falso alerta apoio emoc.
neutro	24	0,92	1,00	1,00	1,00	0,67	0,00
informal	24	0,79	1,00	1,00	0,67	0,50	0,00
regional	24	0,62	0,83	0,67	0,67	0,33	0,00
Geral	72	0,78	0,94	0,89	0,78	0,50	0,00



4.2 Matriz de confusão (total, n=72)

Real \ Previsto	escola	entret.	social.	apoio emoc.	outros
escola	17	0	0	0	1
entretenimento	0	16	0	0	2
socialização	2	1	14	0	1
apoio emocional	1	0	1	9	7

4.3 Por faixa etária

Faixa etária	n	Acurácia	Revocação apoio emocional
6-9	18	0,83	0,50
10-12	18	0,67	0,50
13-15	18	0,83	0,60
16-17	18	0,78	0,40

4.4 Leitura dos resultados

- **A acurácia cai com a distância do português padrão:** 0,92 (neutro), 0,79 (informal) e 0,62 (regional).
- **A categoria mais sensível é a mais afetada:** a revocação de “apoio emocional” é 0,67, 0,50 e 0,33, respectivamente. Das 9 mensagens de apoio emocional não detectadas (de 18), 7 foram para “outros”: o sistema **deixou de sinalizar**, em vez de sinalizar errado.
- **Não houve falso alerta de apoio emocional em nenhum registro** (taxa 0,00). O viés observado é de **subnotificação** para quem escreve de modo informal ou regional, o que cria falsa sensação de segurança (riscos T03 e T06).
- Por faixa etária, a variação (acurácia 0,67 a 0,83) **não é interpretável**, pois as faixas foram atribuídas em rodízio e não refletem diferenças reais de linguagem.

5. Conclusão e limitações

Conclusão. No conjunto sintético, o protótipo v0.1 apresenta desempenho menor em linguagem informal e regional, com efeito concentrado em “apoio emocional”. Isso confirma, como **indício**, o risco T05 e justifica as medidas abaixo. **Não se conclui** ausência de viés nas demais dimensões nem magnitude de viés em usuários reais.

Limitações. (1) Apenas 6 mensagens por célula: uma única mensagem altera a revocação em 0,17; as diferenças não têm significância estatística. (2) Mensagens escritas por adultos; regionalismos limitados ao Nordeste; sem emoji, áudio, abreviações de chat ou erros de digitação. (3) O resultado vale para o classificador por regras e não prevê o desempenho de um LLM, que deve ser reavaliado com o mesmo protocolo. (4) Não foram avaliados atributos sensíveis, conforme a premissa de não inferi-los apenas para produzir métrica de equidade. (5) As faixas etárias não estão equilibradas com a linguagem real.

6. Medidas decorrentes e rastreabilidade

Risco → Impacto	Medida proposta (verificável)	Tipo	Evidência	Como verificar
T05 → alertas ausentes para quem escreve de modo informal ou regional	Ampliar o conjunto de avaliação (cenários consentidos) e o léxico com gírias e regionalismos validados; reavaliar a cada mudança do classificador	Preventiva	Este relatório; artefato 04 (B1, B5)	Repetir avaliacao_vieses.py e comparar revocação por registro
T05 → classificação por tom, não por assunto	Regras 8 e 9 do prompt: gíria não é sinal de risco; na dúvida, “outros” com confiança baixa	Preventiva	Artefato 01 (casos C3 e C4)	Executar os 6 casos de aceitação e conferir confiança baixa
T05, T06 → erros sem correção	Contestação pelo jovem e correção pelo responsável, com revisão humana registrada	Humana	Artefato 06; telas 07 e 08	Auditar o log: decisão, revisor e observação em cada caso
E5 → erro de classificação vira rótulo sobre o jovem (ex.: gíria lida como sofrimento)	Alertas descrevem padrão de uso com confiança baixa em gíria e regionalismo (prompt, regras 8, 9 e 11); varredura de linguagem rotulante; contestação pelo jovem com revisão humana	Preventiva, Detectiva e Humana	Artefatos 01, 06, 08 e 10	Rodar a varredura (aprovada) e auditar CASO-019 a CASO-021 do log
T03 → falsa segurança por subnotificação	Medir revocação por categoria e registro; fixar o limite de diferença aceitável após a linha de base; critério de pausa se o limite for excedido	Detectiva	Este relatório (seção 4)	Relatório regenerado antes de cada release; decisão registrada no log

Histórico: v1.0 · 02/10/2026 · versão inicial · v1.1 · 02/10/2026 · inclusão do risco E5 na seção 6 (o experimento não mudou).